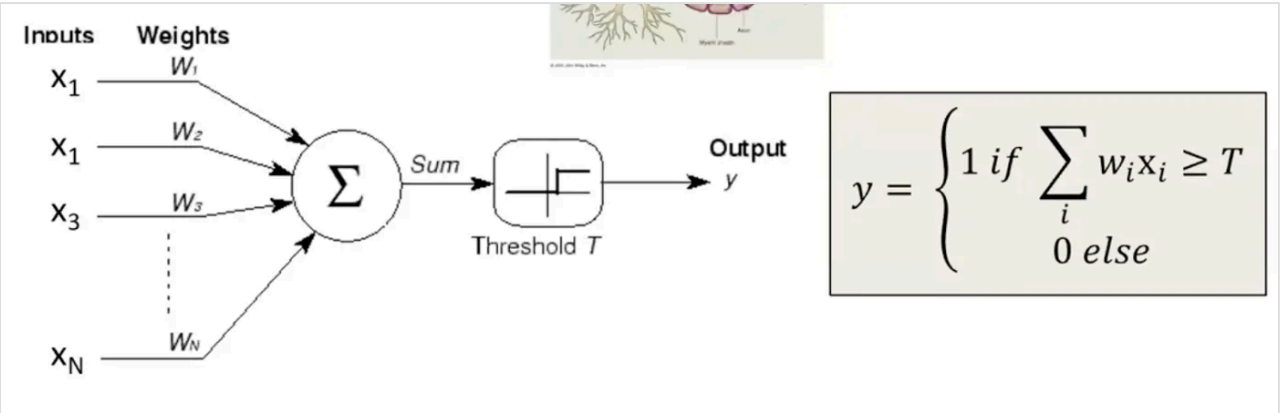
Lec2. Neural Nets as Universal Approximators

what NN?

- function like brain
  brain = networks of neurons

Perceptron



- ※ 캡처 1의 입력 표기에서 두 번째 X_1은 오기이며, X_2로 표기하는 것이 맞음.
- Perceptron은 입력의 가중합 w·x를 임계값 θ와 비교하여, w·x > θ이면 활성화되는 구조임. 여기서 θ는 가중합과 비교되는 기준값이며, bias 자체를 넘는다는 의미는 아님. bias를 사용하는 표현에서는 w·x + b > 0 ⟺ w·x > −b이므로 θ = −b의 관계가 성립함. 캡처 1의 w·x ≥ T라는 표기도 b = −T로 두면 w·x + b ≥ 0으로 동일하게 표현할 수 있음. 단, >와 ≥는 임계값에서의 포함 여부가 다르므로 각각 구분해야 함.

$$z = \sum_i w_i x_i + b$$

$$y = \begin{cases} 1 \; if \; z \geq 0 \\ 0 \; else \end{cases}$$

Logistic

$$y = \frac{1}{1 + exp(-z)}$$

- Perceptron에서 사용하는 step 함수도 activation function(활성화함수)의 일종이며, sigmoid 함수 역시 활성화함수의 한 예임. 입력의 가중합과 bias를 z = w·x + b로 두면, sigmoid 활성화함수를 사용한 출력은 $y = \sigma(z) = 1/(1 + e^{-z})$로 표현됨. Step 함수는 임계값을 기준으로 출력이 불연속적으로 바뀌지만, sigmoid 함수는 연속적인 값을 출력하므로 perceptron의 출력을 보다 soft하게 만들 수 있음. 즉, 활성화함수라는 용어는 sigmoid에만 해당하는 것이 아니라 step 함수 등에도 적용됨.
- affine combination
  점(또는 벡터)들의 linear combination 중 계수의 합이 1인 형태를 의미함. 예를 들어 0.3x + 0.7y는 계수의 합이 1이므로 affine combination임.
- 반면 3x + 7y + 4처럼 입력의 가중합에 constant(bias)가 더해진 형태는 affine function/transformation에 해당함. 일반적으로 f(x) = Wx + b로 표현하며, affine combination과는 구분해야 함.

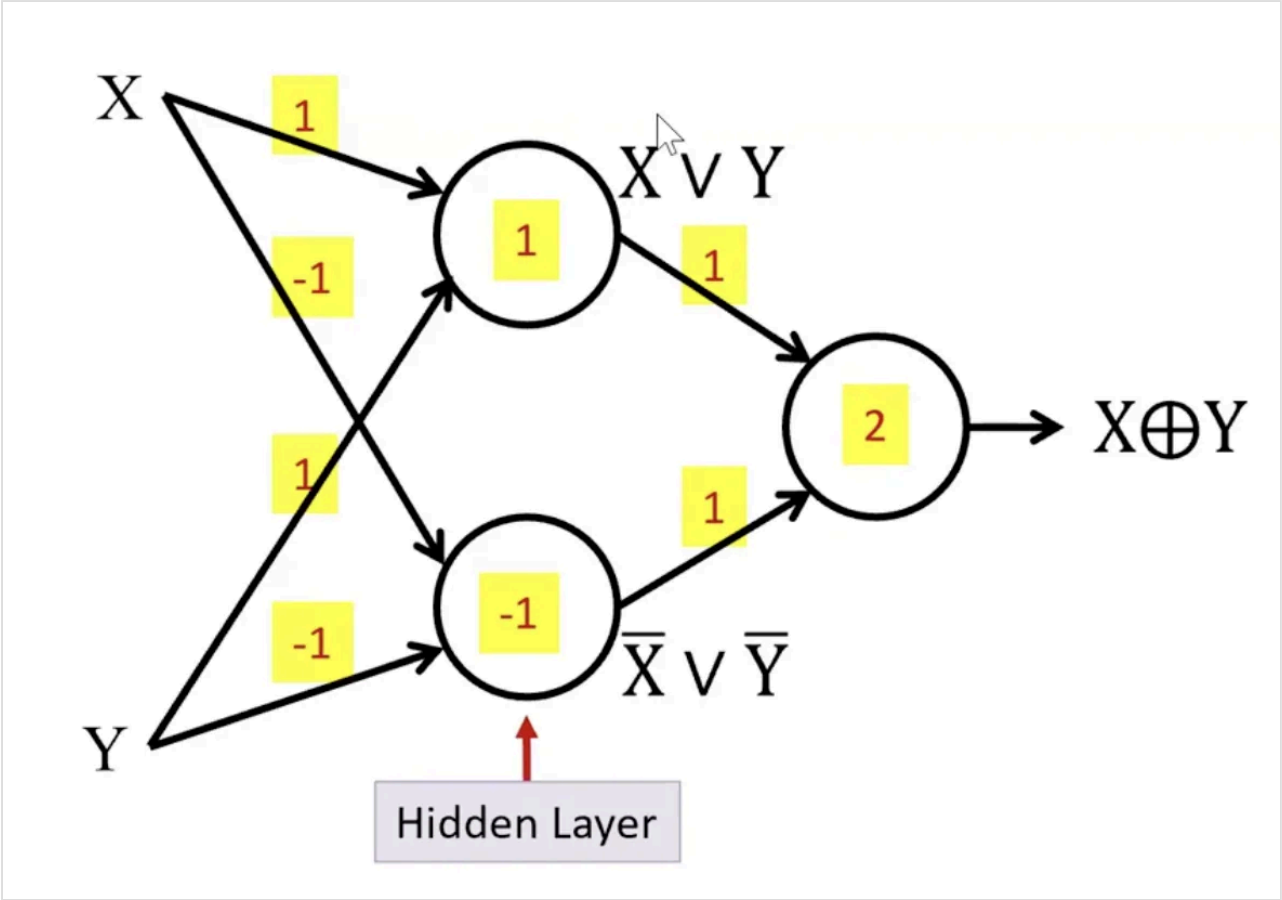
multi-layer perceptron / Depth

- mlp는 depth가 있는 network라고 할 수 있다.

> **depth**는 무엇일까?
> **input(source node) - output까지 path에서 지나는 노드의 개수**

- **Layer의 정의는?**
  set of node - that has same depth

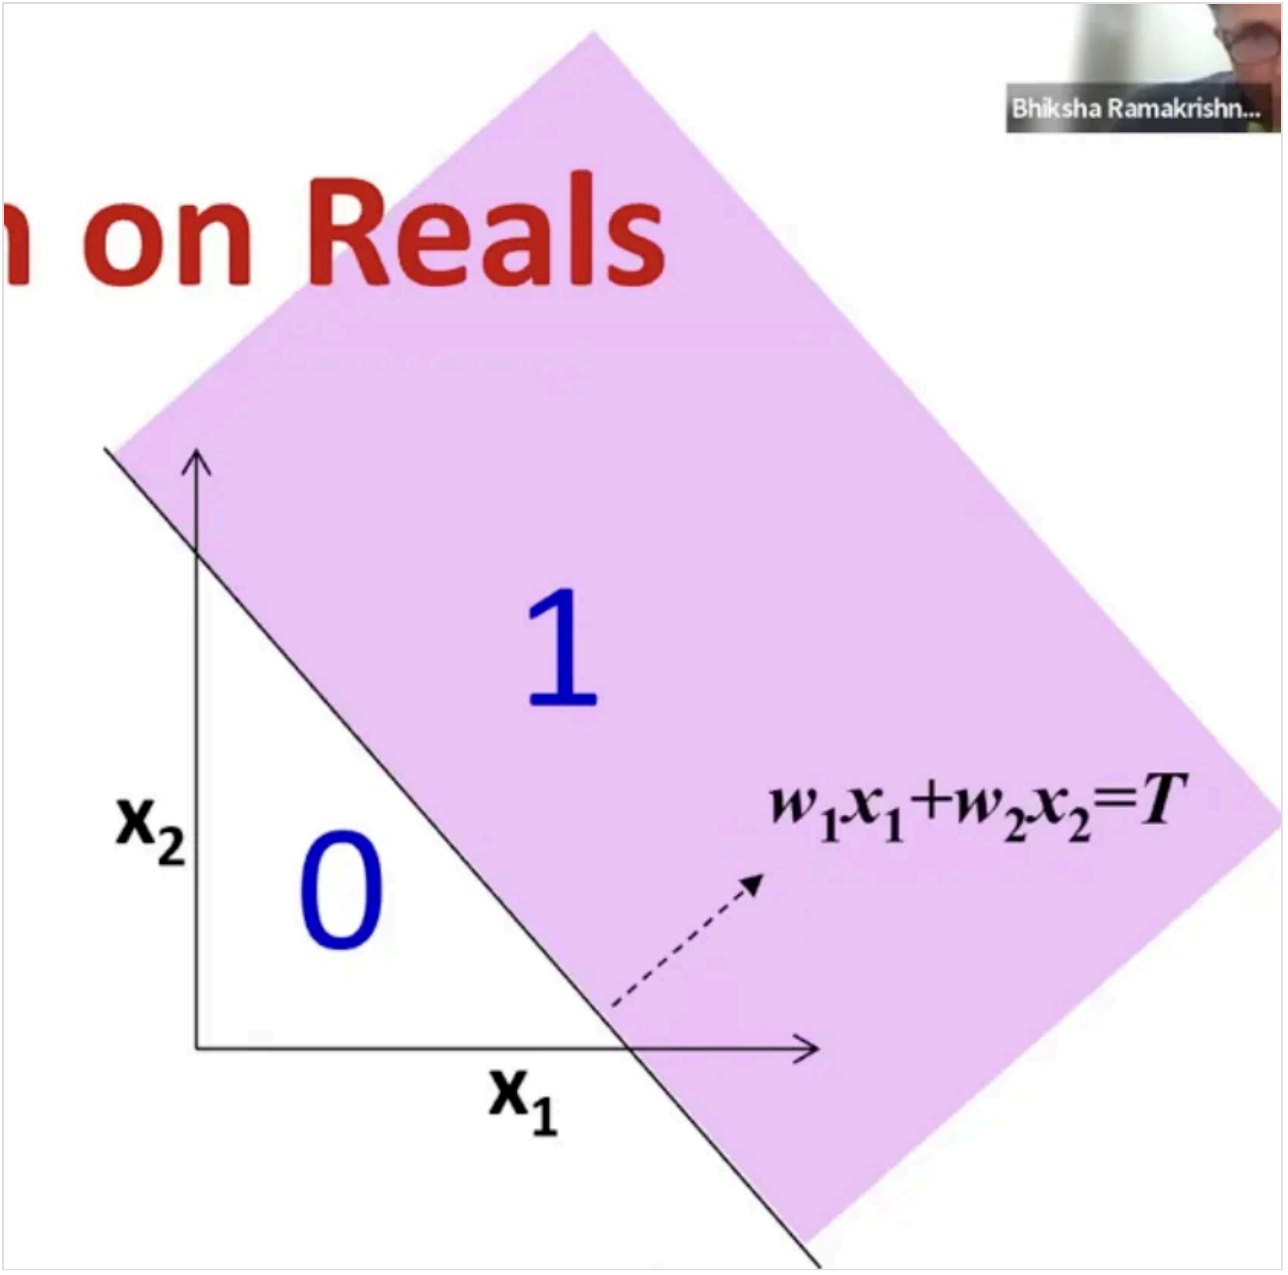
- Mlp는 **boolean functions**이 될 수 있음.



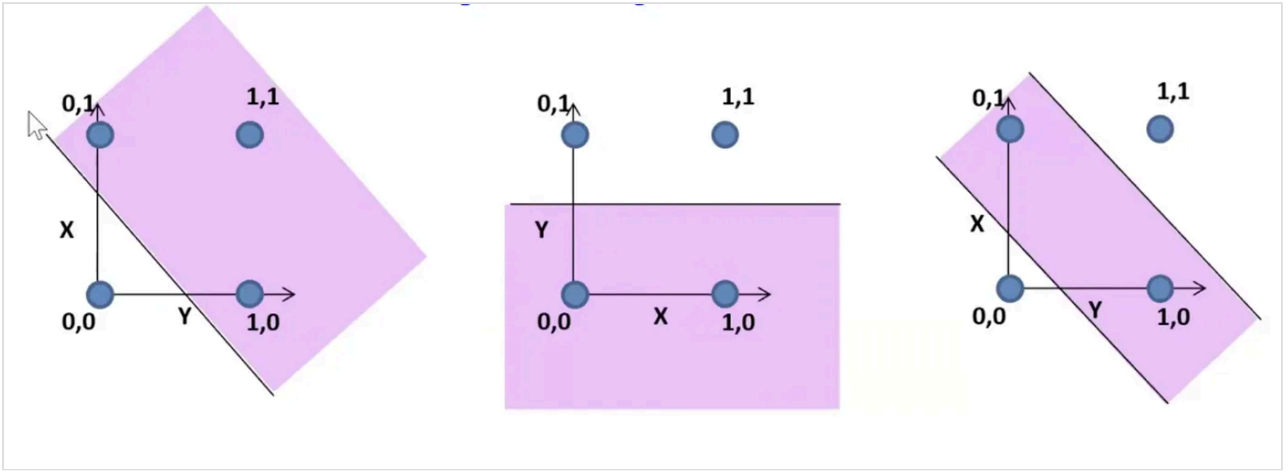
- Edge에는 weight(W)가 부여되고, node에서는 입력의 가중합을 임계값 θ와 비교함. θ는 활성화 여부를 결정하는 기준값이며, bias와는 θ = −b의 관계가 있음. Weight와 bias(또는 임계값 θ)를 적절히 설정하면 AND / OR / NOR 등의 Boolean 함수를 표현할 수 있음. 다만 단일 perceptron이 모든 Boolean 함수를 표현할 수 있는 것은 아니며, 선형적으로 분리할 수 없는 Boolean 함수는 단일 perceptron만으로 표현할 수 없음.
- **어떤 boolean function이든 하나의 hidden layer**로 표현할 수 있음.
  진리표 하나로 표현할 수 있듯이, 한층이면 Truth Table을 모두 표현할 수 있음.

MLP as a classifier

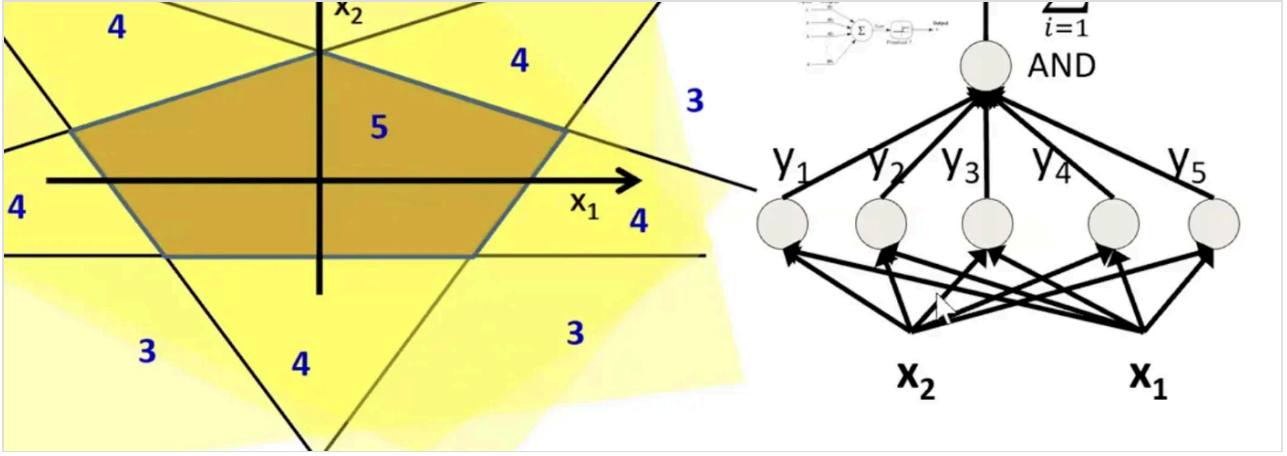
- perceptron은 아래와 같은 hyperplane으로 볼 수 있다.



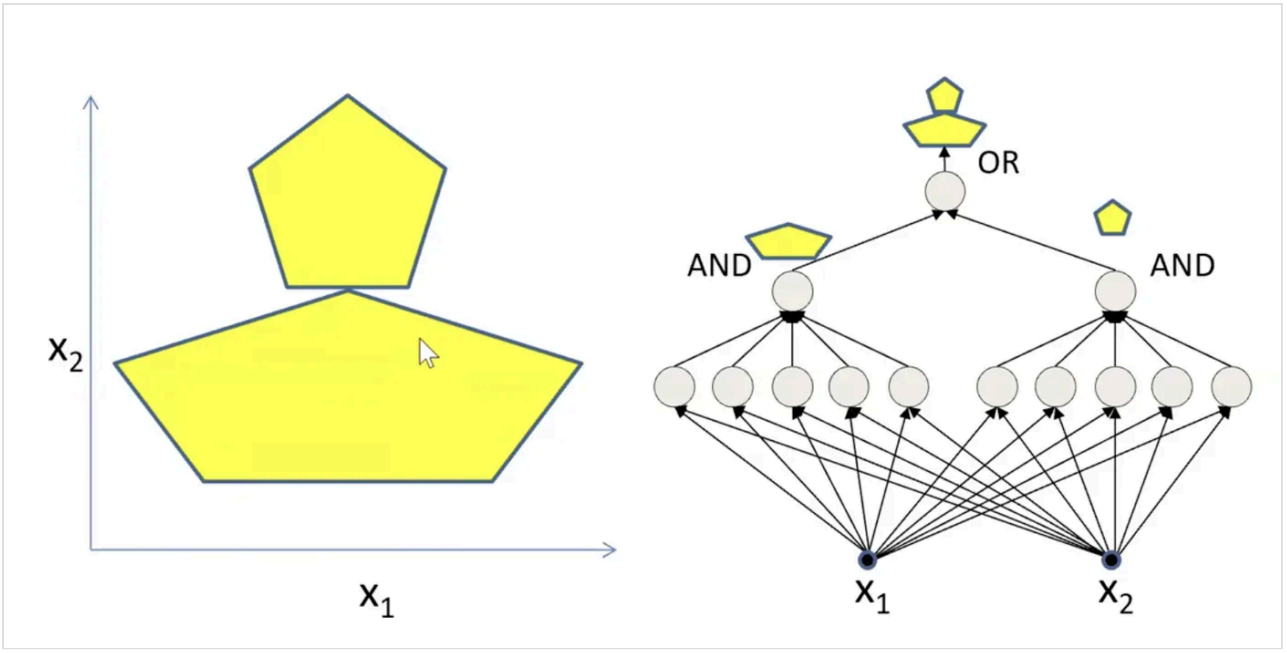
- 경계를 넘으면 → 1이고, 넘지 않으면 0으로 표현됨.



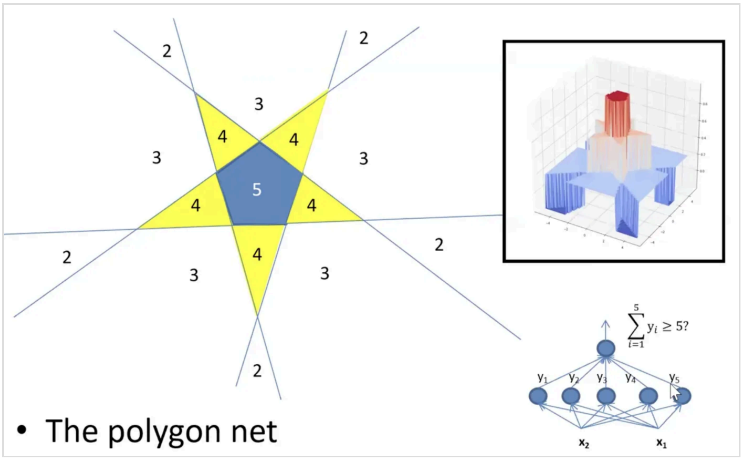
- 오른쪽과 같이 2개의 경계가 필요한 경우(XOR)에는, single perceptron으로 나타낼 수 없다.



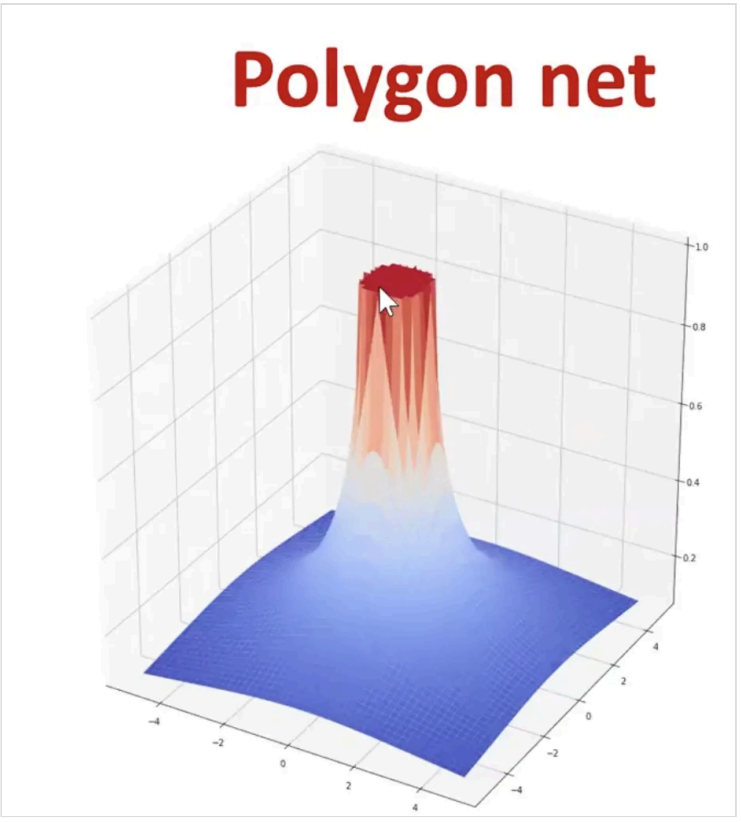
- 각 perceptron이 경계 1개를 만듦 → 5개면 5개의 경계를 만들 수 있음.
  → decision boundaries



- 이를 2개 겹치면 → 2개의 boundaries를 나타낼 수 있음.
  → 이를 통해서 더욱 복잡한 boundaries를 구성할 수 있는 것

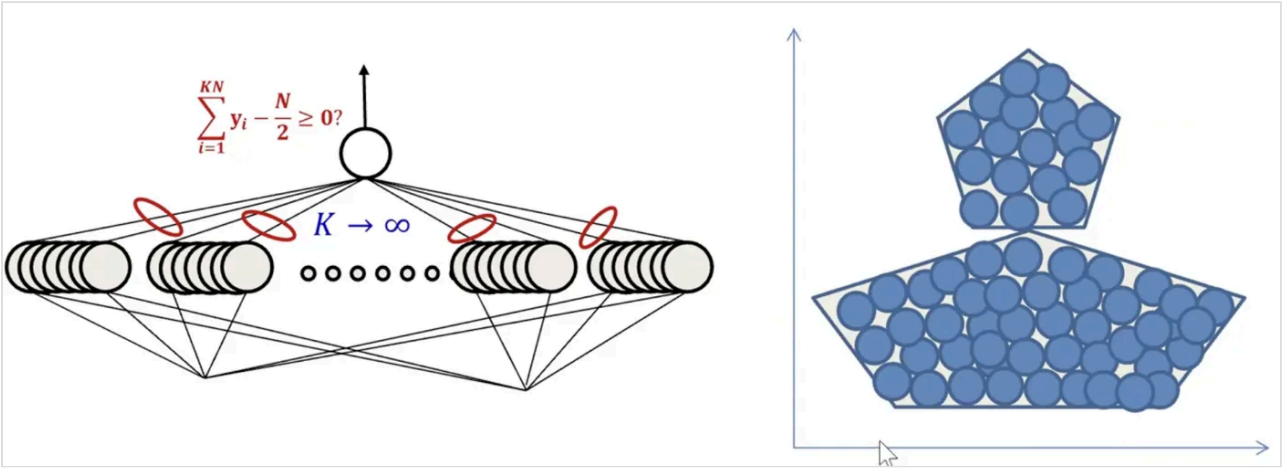


- The polygon net



- 각 뉴런이 다각형의 한 변을 기준으로 안쪽 반평면에 해당하는지를 0 또는 1로 출력한다고 보면, 뉴런의 합은 다각형 내부에서 변의 수 N과 같아짐.
- 다만 경계 바로 바깥에서는 내부와 뉴런의 합이 큰 차이가 나지 않음. 캡처 9의 오각형(N = 5)에서는 내부 합이 5이고, 바깥쪽은 위치에 따라 바로 인접한 영역에서 4, 그 밖에서 3, 먼 영역에서 2로 달라짐. 즉, 외부의 합이 항상 일정한 값으로 나오는 것은 아님.

- 변의 수 N을 늘리면 → 다각형의 경계가 원에 가까워지고, 내부의 뉴런 합 N과 외부의 합 사이의 차이도 외부 위치에 따라 상대적으로 커질 수 있음. 이를 통해 원에 가까운 영역을 더 정밀하게 근사할 수 있음.
- 단, 경계 바로 바깥에서는 여전히 내부와의 차이가 작을 수 있으며, 외부 뉴런의 합이 일률적으로 N/2로 수렴하는 것은 아님.

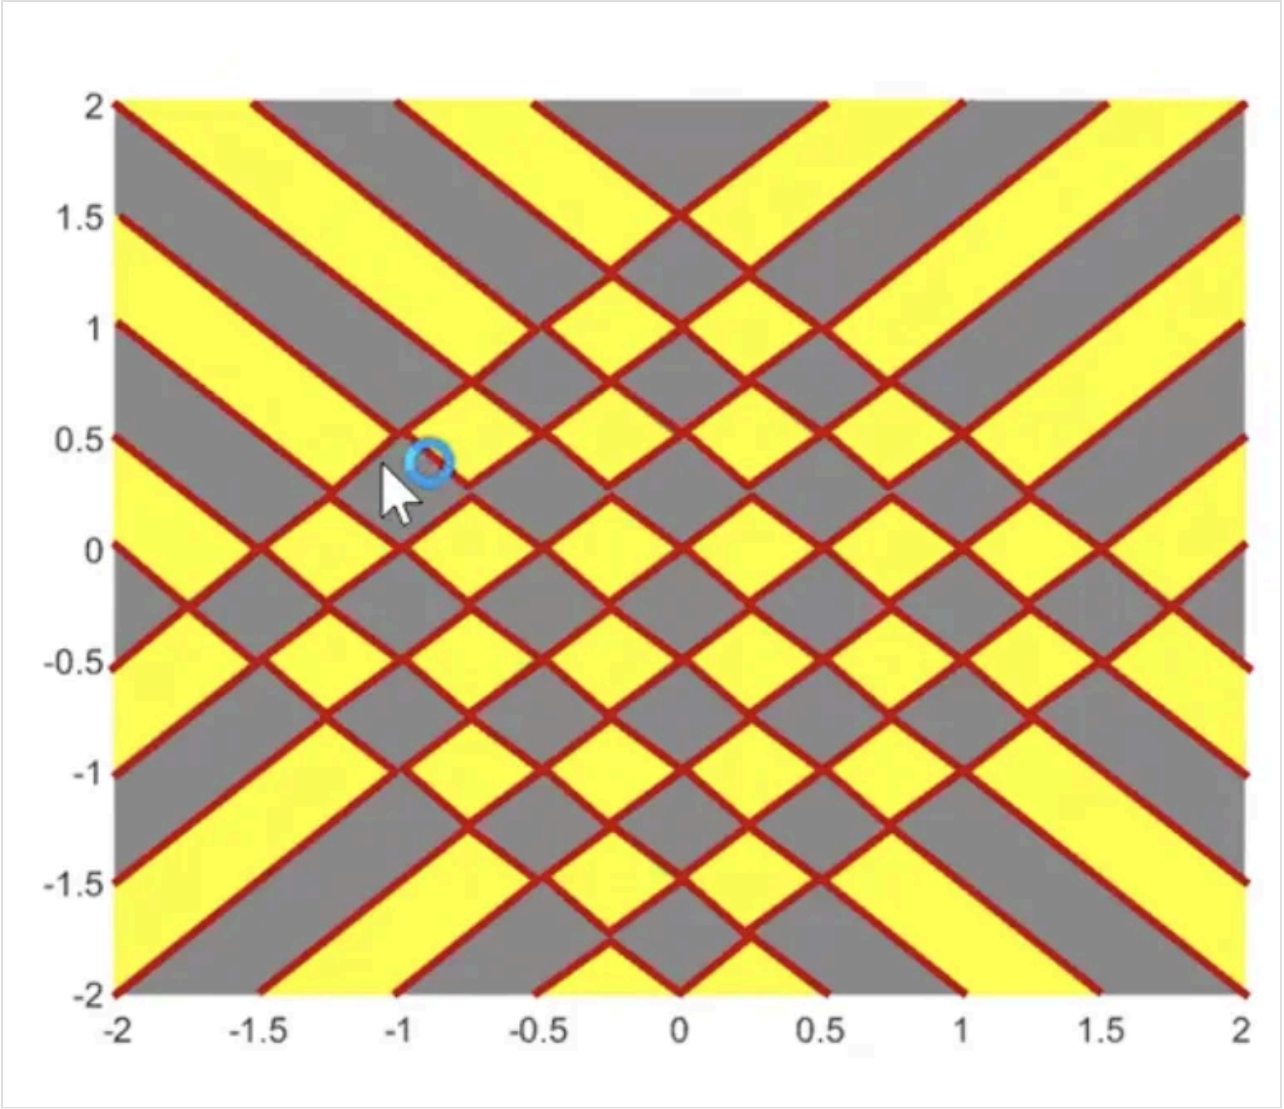


- 캡처 11의 판정식 $\Sigma_{i=1}^{KN} y_i - N/2 \geq 0$은 K개의 다각형을 결합하여 영역을 판정하는 별도의 구성에서 제시된 식임. 여기서 N/2는 해당 결합 구성의 판정 임계값(threshold)이며, 앞서 설명한 단일 N각형의 외부 뉴런 합이 N/2로 수렴한다는 의미는 아님.
- UAT(Universal Approximation Theorem)에 따르면, 콤팩트 집합 K 위의 임의의 연속함수 f에 대해, 연속인 비다항식 활성화함수를 사용하는 **one-hidden-layer MLP**는 충분한 수의 hidden unit을 사용하여 임의의 $\varepsilon > 0$에 대해 $\| f - \hat{f} \|_\infty < \varepsilon$를 만족하는 근사 함수 $\hat{f}$를 존재하게 할 수 있음. 이는 모든

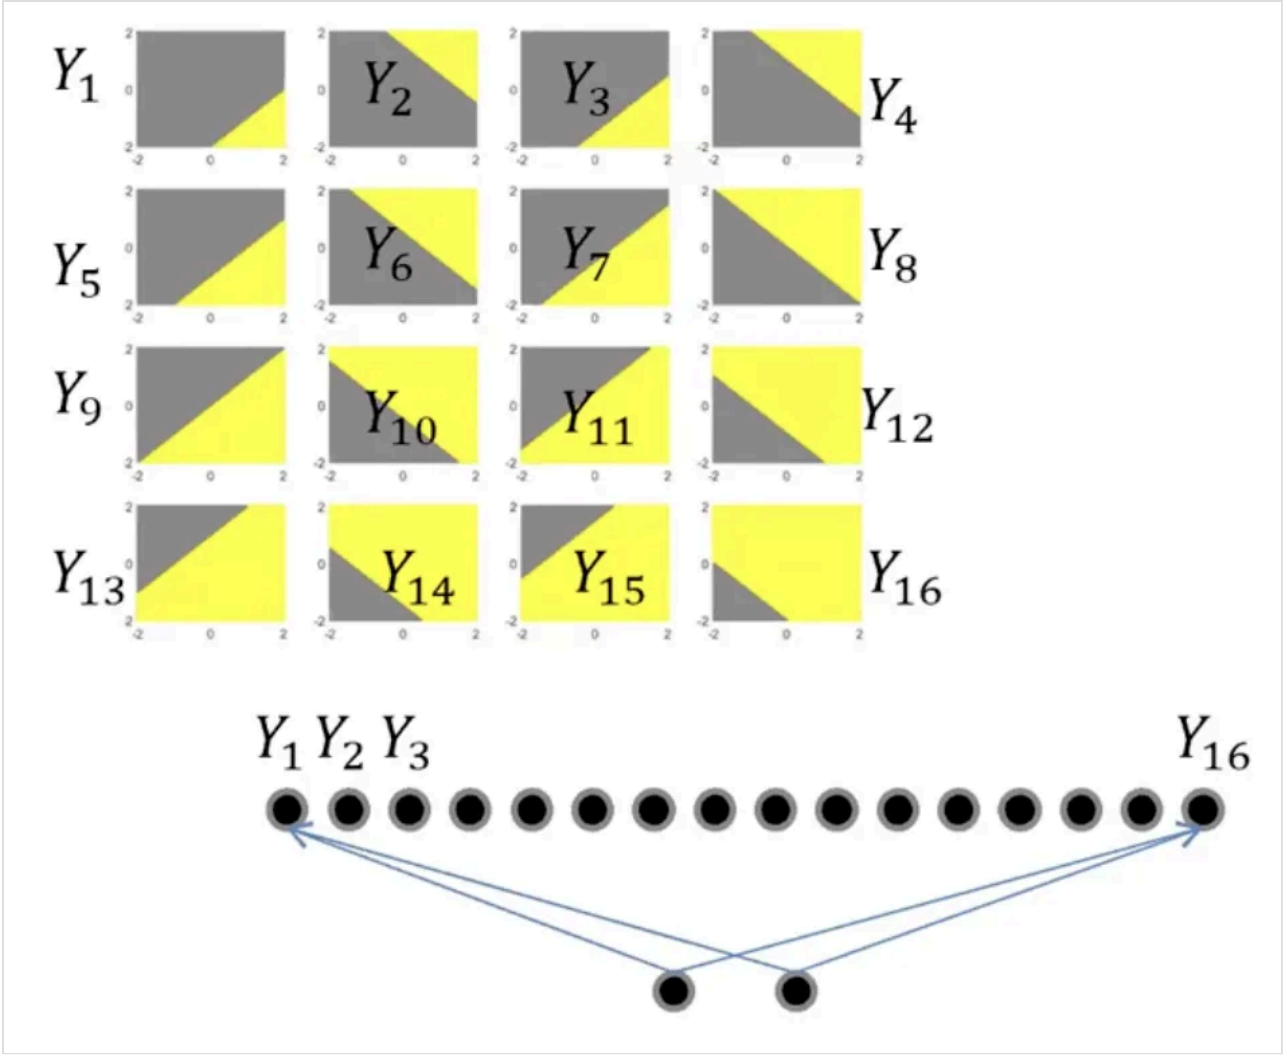
classification 문제를 반드시 '해결'한다는 의미가 아니라 함수 근사가 가능하다는 존재 정리임. 또한 이러한 근사를 실현하는 가중치를 실제 학습 과정에서 반드시 찾을 수 있다는 보장은 없으며, 결정 경계 근처에서는 작은 근사 오차로도 오분류가 발생할 수 있음.

- hidden-layer를 늘리면, 이런 분류를 더욱 효율적으로 할 수도 있음.

Optimal depth



- 이런 복잡한 경계를 one-hidden-layer로 나타내려면 점으로 다 찍어야 함.
- 근데, 퍼셉트론을 2층으로 쌓으면 → 이런 경계를 더 쉽게 나타낼 수 있음.



- 이 경우에는 XOR을 계속 쌓으면 됨.! → 적은 노드로 해결 가능