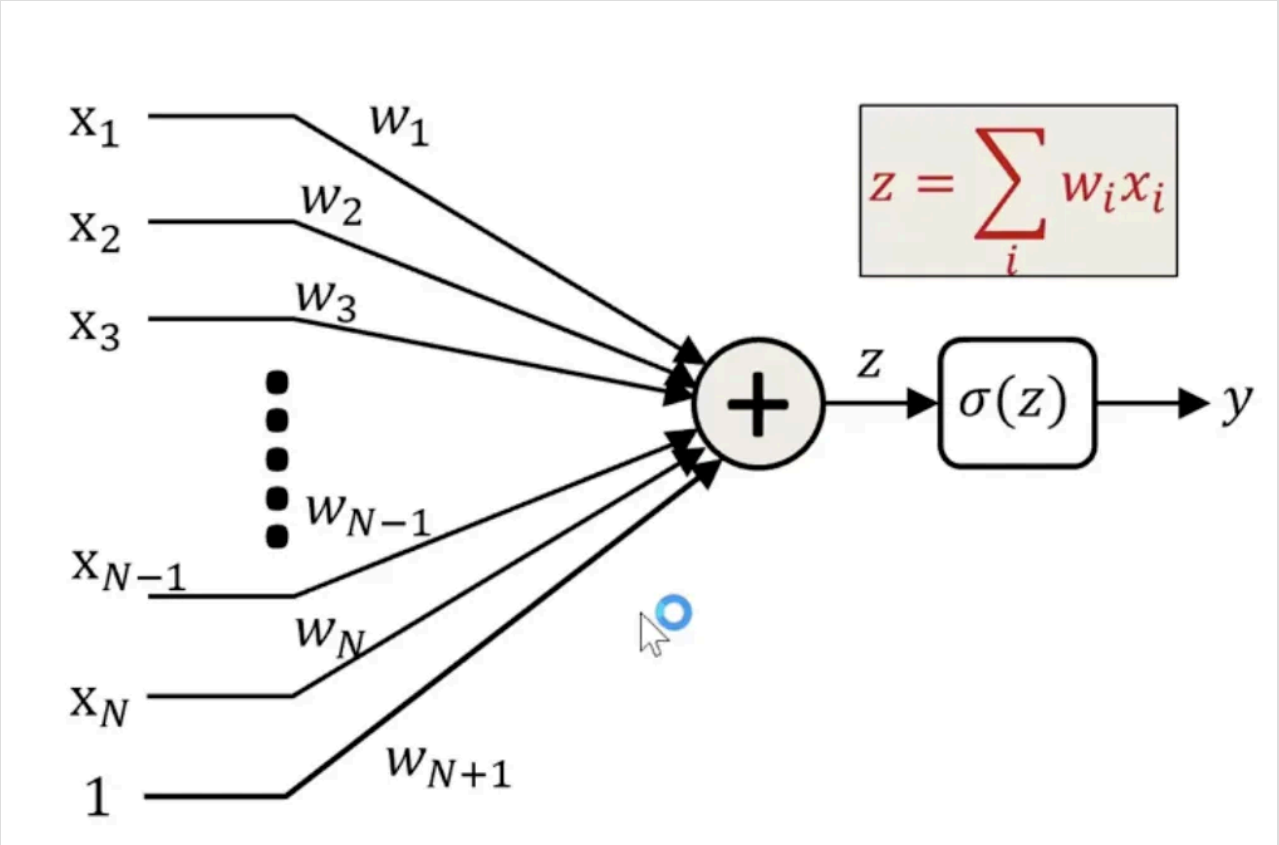
# Lec3. Training Part I

> The Problem of Learning
> Empirical Risk Minimization

- NN
  → boolean, classification, continuous 모두 표현할 수 있음.

---

- Redrawing the neuron

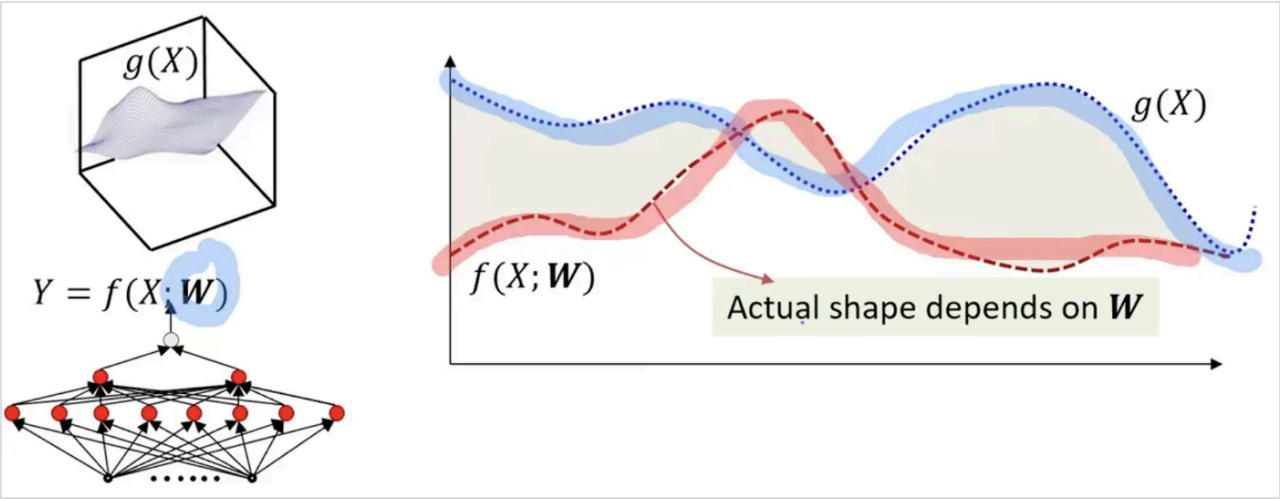



- 이런식으로 X뒤에 1값을 넣으면 → $b = w_{N+1}$ 으로 쉽게 표현될 수 있음

---

## Automatic estimation of an MLP

---




- 정답 $g(X)$ 와 weight에 의존하는 $f(X;W)$간의 오차를 구할 수 있음.
- → 이를 최소화 하는 방향으로, 학습할 수 있음
  → 그럴려면 오차에 해당하는 구간을 정량화할 수 있어야 함.
- $divergence\,function$를 이용해야 함.

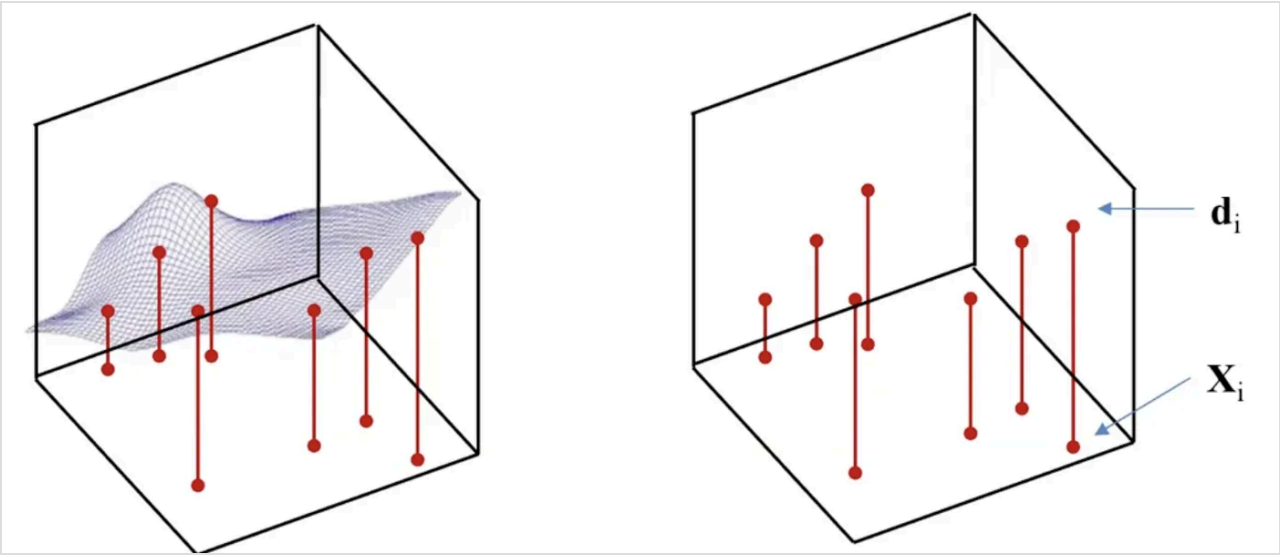
$$totalerr(\boldsymbol{W}) = \int_{-\infty}^{\infty} divergence\big(f(X;\boldsymbol{W}), g(X)\big)dX$$

$$\widehat{\boldsymbol{W}} = \underset{\boldsymbol{W}}{\operatorname{argmin}}\ totalerr(\boldsymbol{W})$$

---

## sampling the function

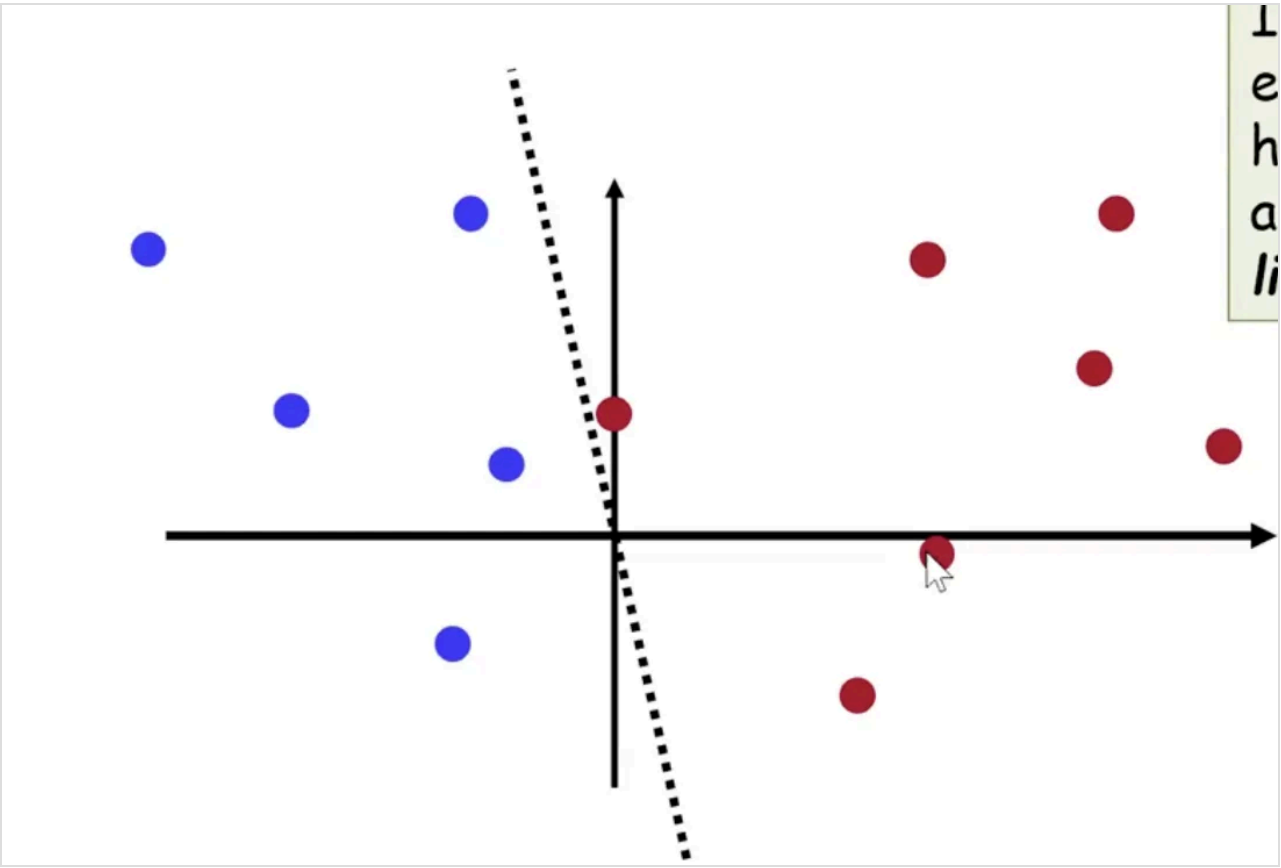
---




- 실제로 g(x)를 알지는 못함 → 대신 g(x)의 sample을 알 뿐임.
  → 현실에서 데이터를 추출하는 과정.
- 우리는 이 샘플을 통해서 전체 function을 추출하려는 거임.

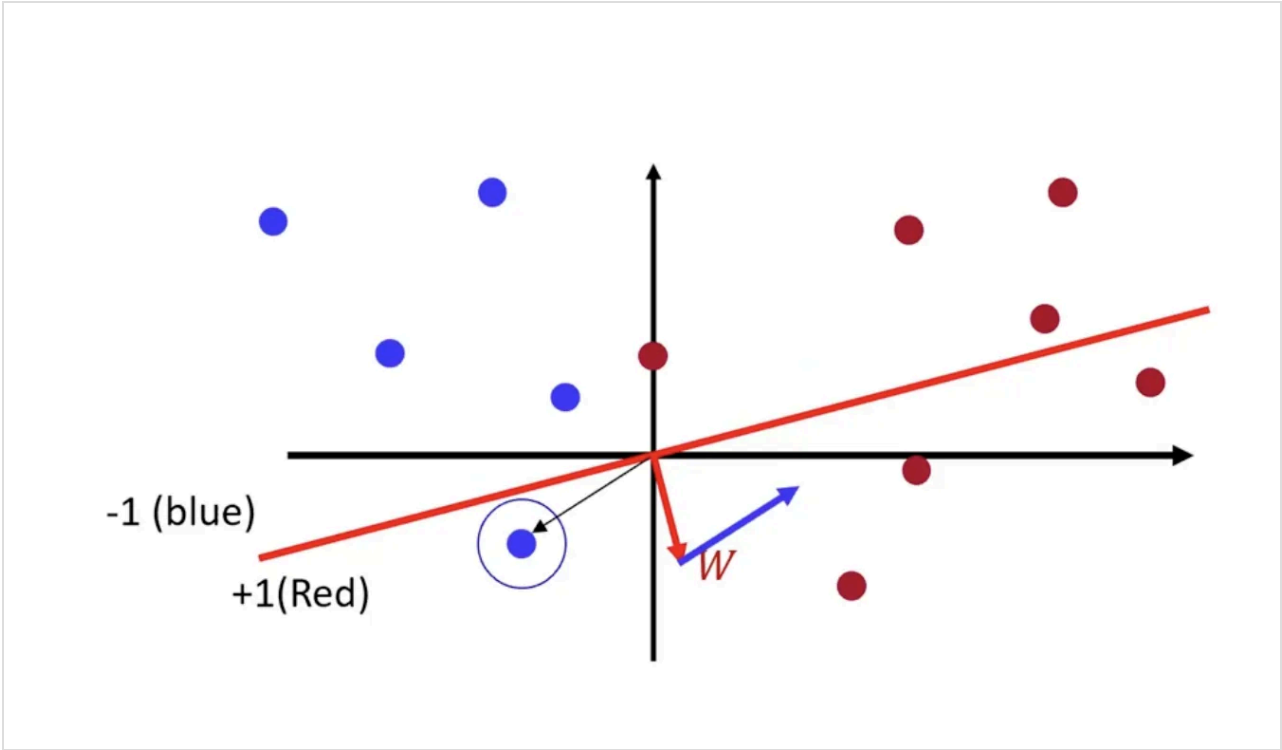
---

- The Perceptron Problem



- 이런 점들을 hyperplane으로 분리하는 것이 문제임.
  우리는 이런 점들을 hyperplane으로 구분할 수 있다고 가정하고 있음.

- 선을 기준으로, WX가 양수/음수를 구분할 수 있음




- 위와 같이 오류가 생긴 점이 있으면, 그 점의 반대 방향으로 W 벡터를 이동하면 됨. 즉 $(W - X)$를 하면 됨

---

## problem

- **binary error** metric → not useful
- 어떤 방향으로 최적화할지에 대한 것을 제시할 수 있어야 한다.
  W를 바꿨을 때, 이게 좋은 방향으로 가고 있는지. 그 error를 보여줄 수 있을 방안이 필요하다.
  → 그래서, perceptron들이 미분 가능해야 학습하기 좋다.
- → Solution : **Differentiable activation function**

---

## error function

- $div(f(X;\boldsymbol{W}), g(X)) = 0$ if $f(X;\boldsymbol{W}) = g(X)$
- $div(f(X;\boldsymbol{W}), g(X)) > 0$ if $f(X;\boldsymbol{W}) \neq g(X)$

- div를 통해 → 차이가 있는지를 보는 거임.

$$\widehat{\boldsymbol{W}} = \underset{W}{\operatorname{argmin}} \int_X div(f(X;W), g(X))P(X)dX$$
$$= \underset{W}{\operatorname{argmin}}\, E[div(f(X;W), g(X))]$$

- 단순히 div를 적분하는 게 아니라, P로 자주 나오는지에 대한 가중치도 두게 됨.
- → 최종적으로 div를 최소화 시키는 W를 찾게 되는 거임.