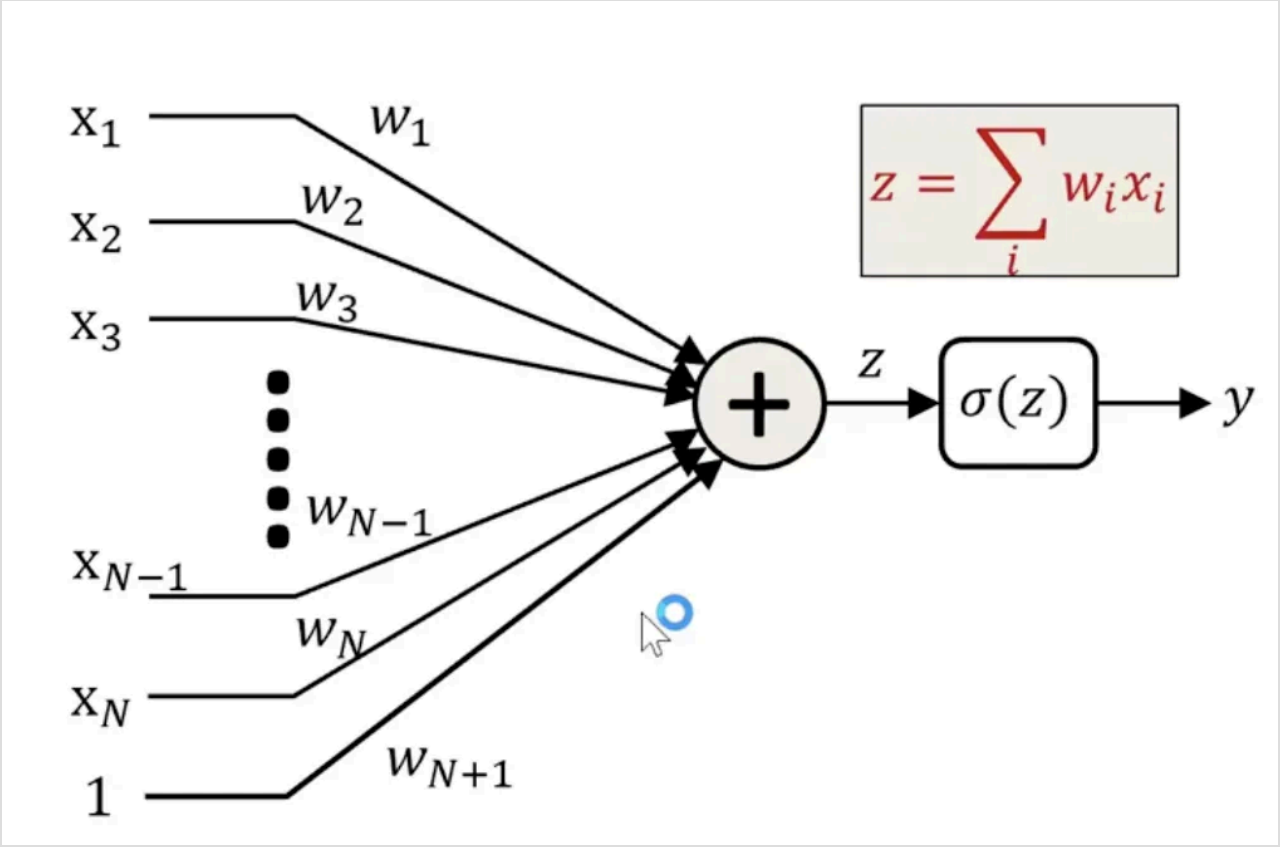
Lec3. Training Part I

> The Problem of Learning
> Empirical Risk Minimization

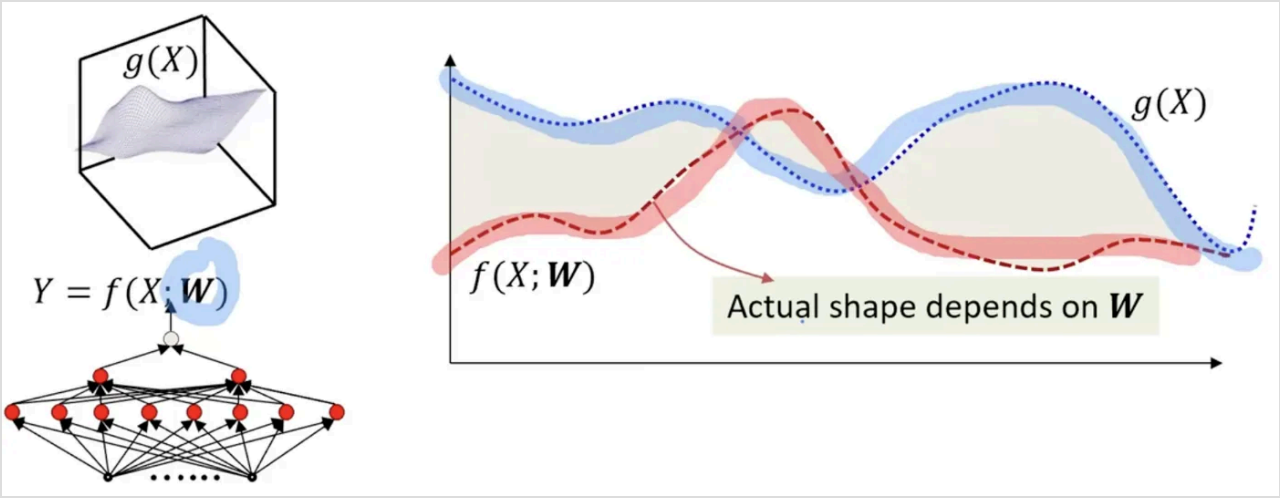
- 신경망은 구조와 활성함수, 모델 용량에 따라 유한한 이진 입력의 Boolean 함수나 분류 결정함수를 표현할 수 있으며, 적절한 비선형 활성함수와 충분한 모델 용량을 갖추면 유계이고 닫힌 정의역의 연속 함수를 원하는 정확도로 근사할 수 있음. 다만 모든 함수를 임의의 유한한 신경망이 정확히 표현할 수 있다는 의미는 아님.

- Redrawing the neuron



- 이런식으로 X뒤에 1값을 넣으면 → $b = w_{N+1}$ 으로 쉽게 표현될 수 있음

Automatic estimation of an MLP



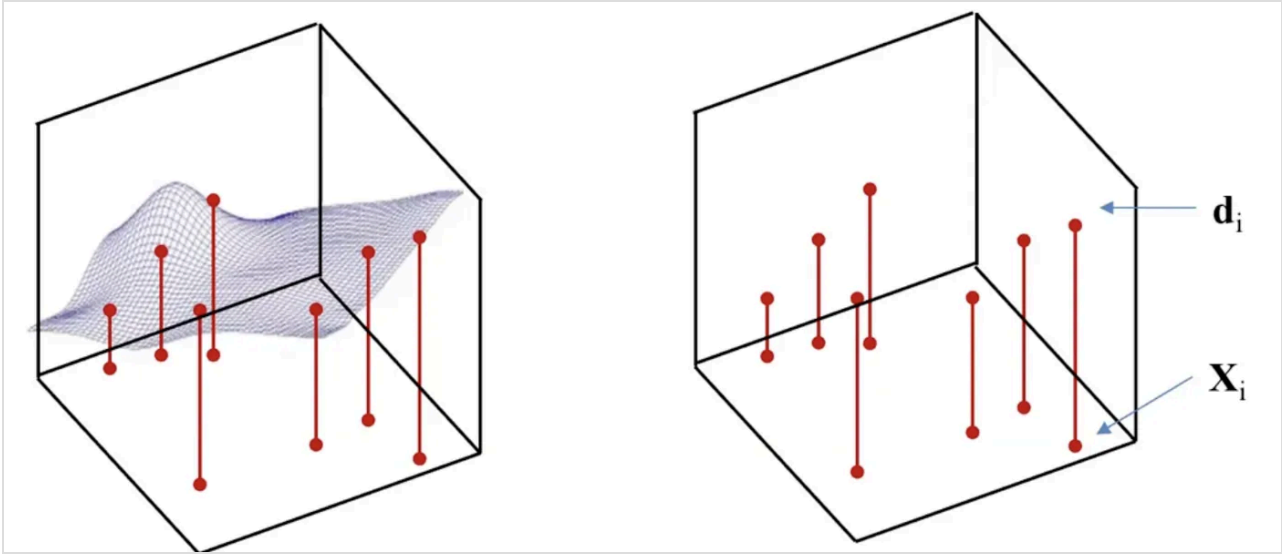
- 정답 $g(X)$ 와 weight에 의존하는 $f(X;W)$간의 오차를 구할 수 있음.
- → 이를 최소화 하는 방향으로, 학습할 수 있음
  → 그럴려면 오차에 해당하는 구간을 정량화할 수 있어야 함.
- $divergence function$ 를 이용해야 함.
- 보충: 예측 함수 f(X;W)와 정답 g(X)의 차이를 정량화하기 위해 문제에 적합한 손실함수 ℓ(f(X;W),g(X))를 정의해야 함. 예를 들어 회귀 문제에서는 제곱오차 ℓ=(f(X;W)−g(X))²를 사용할 수 있고, 분류 문제에서는 교차엔트로피 등을 사용할 수 있음. 이후 정의한 손실의 평균을 최소화하는 방향으로 가중치 W를 학습함.

$$totalerr(\boldsymbol{W}) = \int_{-\infty}^{\infty} divergence\big(f(X;\boldsymbol{W}), g(X)\big)dX$$

$$\widehat{\boldsymbol{W}} = \underset{\boldsymbol{W}}{\operatorname{argmin}}\ totalerr(\boldsymbol{W})$$

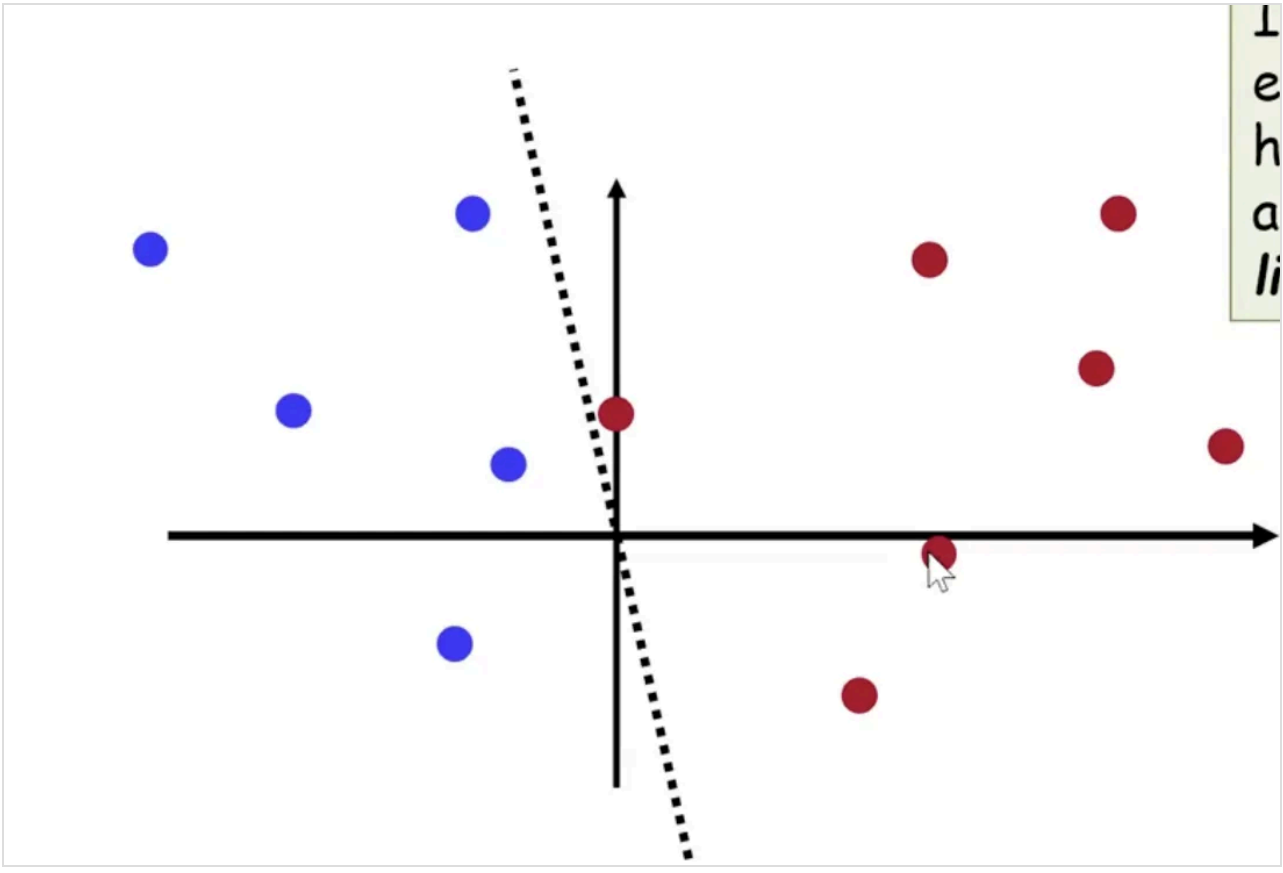
---

sampling the function



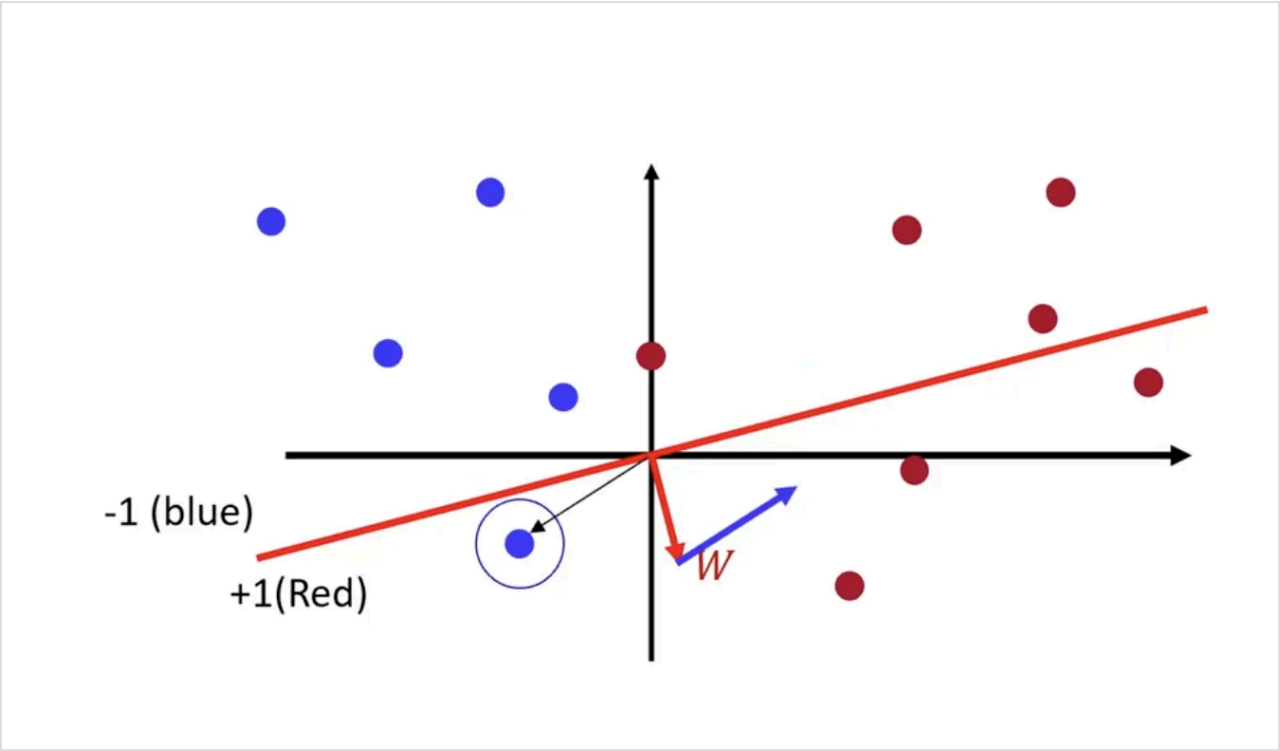
- 실제로 g(x)를 알지는 못함 → 대신 g(x)의 sample을 알 뿐임.
  → 현실에서 데이터를 추출하는 과정.
- 실제 목표 함수 g(x) 전체를 알 수 없으므로 관측된 데이터 샘플 $\{(x_i,d_i)\}_{i=1}^{N}$을 이용해 이를 근사하는 함수 f(x;W)를 학습함. 유한한 샘플만으로 임의의 목표 함수를 정확히 복원할 수는 없으며, 적절한 모델과 데이터에 관한 가정 아래 관측하지 않은 입력에서도 예측 오차가 작도록 일반화하는 것이 목표임.

- The Perceptron Problem



- 이런 점들을 hyperplane으로 분리하는 것이 문제임.
  우리는 이런 점들을 hyperplane으로 구분할 수 있다고 가정하고 있음.

- 선을 기준으로, WX가 양수/음수를 구분할 수 있음



- 퍼셉트론은 레이블 $y_i \in \{-1,+1\}$에 대해 $y_i(w^\top x_i+b) \leq 0$인 잘못 분류된 표본이 있으면, $w \leftarrow w+\eta y_i x_i$, $b \leftarrow b+\eta y_i$로 가중치와 bias를 갱신함($\eta>0$). 그림 속 파란 점은 $y_i=-1$이므로 학습률이 1일 때 $W \leftarrow W-X$가 되지만, 잘못 분류된 빨간 점($y_i=+1$)이라면 $W \leftarrow W+X$로 갱신해야 함.

---

problem

- Binary error(0–1 loss)는 예측이 맞으면 0, 틀리면 1을 부여하는 지표로 분류 성능을 평가하는 데 유용함. 그러나 가중치가 조금 변해도 예측 레이블이 유지되면 손실이 변하지 않아 기울기가 대부분의 지점에서 0이고, 결정 경계에서는 미분이 불가능하므로 일반적인 경사하강법의 학습 목적함수로 직접 사용하기 어려움. 따라서 교차엔트로피나 hinge loss 등 최적화에 더 적합한 대리 손실함수를 사용할 수 있음.
- 어떤 방향으로 최적화할지에 대한 것을 제시할 수 있어야 한다.
  W를 바꿨을 때, 이게 좋은 방향으로 가고 있는지. 그 error를 보여줄 수 있을 방안이 필요하다.
  경사 기반 최적화를 적용하려면 활성함수뿐 아니라 모델과 손실함수를 합성한 학습 목적함수 L(W)가 가중치 W에 대해 미분 가능하거나 적절한 부분기울기를 사용할 수 있어야 함. 계단 활성함수는 일반적인 역전파 학습에 필요한 유용한 기울기를 제공하기 어려우므로 sigmoid, tanh, ReLU 등의 활성함수를 활용할 수 있음. 다만 미분 가능한 활성함수가 모든 학습 방법의 필수조건은 아니며, 고전적 퍼셉트론 갱신법은 계단 활성함수를 사용해도 학습할 수 있음.

error function

$$- \quad div\big(f(X;\boldsymbol{W}), g(X)\big) = 0 \text{ if } f(X;\boldsymbol{W}) = g(X)$$
$$- \quad div\big(f(X;\boldsymbol{W}), g(X)\big) > 0 \text{ if } f(X;\boldsymbol{W}) \neq g(X)$$

- div를 통해 → 차이가 있는지를 보는 거임.

$$\widehat{\boldsymbol{W}} = \underset{W}{\operatorname{argmin}} \int_X div\big(f(X;W), g(X)\big)P(X)dX$$
$$= \underset{W}{\operatorname{argmin}}\, E\big[div\big(f(X;W), g(X)\big)\big]$$

- 단순히 div를 적분하는 게 아니라, P로 자주 나오는지에 대한 가중치도 두게 됨.
- Population Risk는 전체 데이터 분포에 대한 기대손실 $R(W)=E_{(x,y)\sim p}[\ell(f(X;W),Y)]$로 정의됨. 하지만 실제로는 데이터 분포 P를 완전히 알 수 없으므로 이 기대값을 직접 계산하기 어려움. 따라서 학습 데이터 $D=\{(x_i,y_i)\}_{i=1}^{N}$을 이용하여 경험위험 $\hat{R}_N(W)=(1/N)\sum_{i=1}^{N}\ell(f(x_i;W),y_i)$를 정의하고, $\hat{W}\in\operatorname{argmin}_W \hat{R}_N(W)$를 구하는 것이 Empirical Risk Minimization(ERM)임. 잡음이 없는 목표 함수 모델에서는 $y_i=g(x_i)$로 볼 수 있으며, 독립이고 동일한 분포에서 추출된 표본의 평균 손실은 모집단 기대손실의 추정량이 됨.