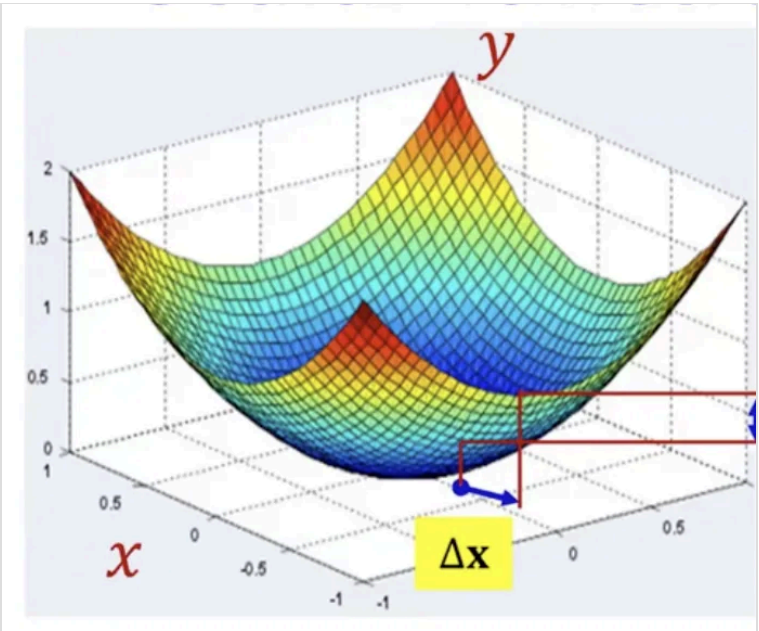
Lec4. Training Part II

function optimization



$$\Delta y = \nabla_x y \Delta x$$

- 미분의 Notation을 이렇게 씀.

$$\nabla_x y = \left[\frac{\partial y}{\partial x_1} \quad \cdots \quad \frac{\partial y}{\partial x_D} \right]$$

- 벡터로서, 각 요소가 편미분인 것.

$$\nabla_X f(X) = \left[\frac{\partial f(X)}{\partial x_1} \quad \frac{\partial f(X)}{\partial x_2} \quad \cdots \quad \frac{\partial f(X)}{\partial x_n} \right]$$

- Gradient = $\nabla_x f(x)^T$
- 정정: 다변수 함수 y=f(x)가 x에서 미분 가능하면, 충분히 작은 입력 변화 Δx에 대해 출력 변화는 Δy=f(x+Δx)−f(x)≈∇ₓf(x)Δx로 1차 근사할 수 있다. 여기서 ∇ₓf(x)는 행벡터 형태의 Jacobian이며, 열벡터 Gradient 표기에서는 Δy≈∇f(x)ᵀΔx로 쓴다. 일반적인 비선형 함수에서는 유한한 변화량에 대해 정확한 등식이 아니다.

Hessian → second derivative of f

$$\nabla^2_x f(x_1,\ldots,x_n) := \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Minimium of function

> 미분 가능한 함수 f가 정의역의 내부점 x*에서 국소 최솟값을 가지면 f′(x*)=0이 필요조건이다. 그러나 이 조건만으로 최소점이라고 결론 내릴 수 없으며, 최대점이나 극값이 아닌 정지점도 도함수가 0일 수 있다. 또한 경계점이나 미분 불가능한 점에서도 최솟값이 존재할 수 있으므로, 정지점을 찾은 뒤 추가적인 판정이 필요하다.

Check the double derivative at x_{soln} : compute

$$f''(x_{soln}) = \frac{df'(x_{soln})}{dx}$$

If $f''(x_{soln})$ is positive x_{soln} is a minimum

- If it is negative, it is a maximum

- f′(x*)=0이고 f가 해당 점 근방에서 두 번 미분 가능할 때, f′′(x*)>0이면 x*는 엄격한 국소 최소점이고, f′′(x*)<0이면 엄격한 국소 최대점이다. 반면 f′′(x*)=0이면 이계도함수 판정법만으로는 극값 여부를 결정할 수 없으며, 추가적인 분석이 필요하다. 이 판정은 전역 최적성을 보장하지 않는다.

Unconstrained Minimization of Function(Multivariate)

- $\nabla_X f(X) = 0$ and
  Hessian Matrix $\nabla_X^2 f(X)$
  - 다변수 함수 $f:R^n \to R$가 두 번 연속 미분 가능하고 $\nabla f(x^*)=0$일 때, $H=\nabla^2 f(x^*)$의 정부호성을 검사한다. Hessian이 양의 정부호(모든 고유값이 양수)이면 x^*는 엄격한 국소 최소점이고, 음의 정부호(모든 고유값이 음수)이면 엄격한 국소 최대점이다. 양수와 음수 고유값이 모두 존재하는 부정부호 행렬이면 x^*는 안장점이다. Hessian이 양의 준정부호 또는 음의 준정부호이지만 정부호는 아닌 경우에는 이 판정법만으로 극값 여부를 확정할 수 없다.

Approach of Gradient Descent



- 경사하강법은 현재 위치에서 Gradient의 반대 방향으로 이동하여 손실을 줄이는 최적화 방법이다. 미분 가능한 함수에서 Gradient가 0이 아니면 음의 Gradient는 국소적인 하강 방향이며, 충분히 작은 양의 학습률을 사용하면 함수값을 감소시킬 수 있다. 갱신식은 $x_{k+1}=x_k-\eta_k \nabla f(x_k)$이고, $\eta_k>0$는 학습률이다. 학습률이 지나치게 크면 손실이 오히려 증가할 수 있으며, 비볼록 함수에서는 전역 최솟값 도달이 일반적으로 보장되지 않는다.

Gradient Descent to train a network

Initialize:

$-W^0$

$-k=0$

do

$-W^{k+1}=W^k-\eta^k\nabla Loss(W^k)^T$

$-k=k+1$

while $\left|Loss\left(W^k\right)-Loss\left(W^{k-1}\right)\right|>\varepsilon$

- 보충: 신경망을 경사하강법으로 학습할 때는 먼저 가중치와 편향을 포함한 파라미터 $W^{(0)}$를 초기화한다. 각 반복에서 현재 파라미터로 순전파를 수행해 예측값과 손실 $L(W^{(k)})$를 계산하고, 연쇄법칙에 기반한 역전파로 손실의 Gradient를 구한다. 이후 학습률 $\eta_k>0$를 사용하여 $W^{(k+1)}=W^{(k)}-\eta_k \nabla_W L(W^{(k)})$로 파라미터를 갱신한다. 여기서는 Gradient를 열벡터로 표기했으며, 행벡터 미분 표기에서는 이를 전치하여 사용한다. 전체 학습 데이터의 Gradient를 사용하면 배치 경사하강법이고, 미니배치로 계산한 Gradient를 사용하면 미니배치 확률적 경사하강법이다.
- 보충: 경사하강법은 연속된 두 반복의 손실 차이 $|L(W^{(k)})-L(W^{(k-1)})|$가 미리 정한 허용오차 $\varepsilon>0$ 이하가 되면 종료하도록 구현할 수 있다. 그러나 손실 변화량이 작다는 사실만으로 최적점 도달이나 Gradient가 0에 가까워졌음을 보장할 수는 없다. 따라서 실제 구현에서는 Gradient 크기 $\#\nabla_W L(W^{(k)})\#$, 손실 변화량, 최대 반복 횟수 등의 조건을 함께 고려하는 것이 바람직하다.